

Домашнее задание 3: Model tracking

Стек:

- Docker compose,
- Spark,
- Minio,
- Redis,
- Airflow,
- MLflow.

Цель задания

Настроить среду с помощью Docker Compose, включающую:

- скачивание данных movielens,
- разбиение датасета на обучающий и тестовый,
- создание признаков с использованием Spark,
- медленное хранилище данных Minio,
- быстрое хранилище для признаков Redis,
- обучение простой модели на признаках из parquet,
- валидацию простой модели на признаках из Redis,
- запись метрик обучения и валидации модели с помощью MLflow,
- оркестрацию этого процесса с помощью Airflow.

Вам понадобятся:

- Датасет latest из <https://grouplens.org/datasets/movielens/>
- Docker + Docker Compose
- Любой редактор кода, подсветить синтаксис Python и Docker поможет VSCode или Cursor

Задача

1. Создать проект с такой структурой:

```
hw3_{Фамилия_Имя}
├── minio/
│   └── data
├── spark/
│   ├── Dockerfile
│   ├── entrypoint.sh
│   ├── requirements.txt
│   └── ...
├── airflow/
│   └── dags/
```

```

├── Dockerfile
├── requirements.txt
├── ...
├── spark-jobs
├── ...
├── mlflow
├── Dockerfile
├── train_model.py
├── requirements.txt
├── ...
├── docker-compose.yml
└── run.sh

```

2. Обучаем модель логистической регрессии с бинарным признаком “поставит ли пользователь оценку 4 и выше”.
 - 2.1. В MLflow записываем метрики
 - accuracy
 - roc_auc
 - precision
 - recall
 - f1_score
 - 2.2. Features engineering - по вашему вкусу.
3. В проекте должны быть:
 - 3.1. Dockerfiles для Spark и Airflow с нужными вам библиотеками
 - 3.2. DAG Airflow с задачами
 - 3.2.1. **get_dataset** - скачивание и распаковка датасета
 - 3.2.2. **put_dataset** - размещение датасета в minio
 - 3.2.3. **split_dataset** - разделение датасет
 - 3.2.4. **features_engineering_train** - обработка датасета с помощью Spark и складывание его в parquet для обучения модели
 - 3.2.5. **features_engineering_test** - обработка датасета с помощью Spark и складывание его в parquet для инференса модели
 - 3.2.6. **load_features** - чтение тестового parquet и загрузка данных в redis
 - 3.2.7. **train_and_save_model** - обучение модели и сохранение ее в mlflow
 - 3.3. DAG может содержать любое количество вспомогательных задач с любыми именами
 - 3.4. Файл docker-compose, в котором обязательно должны быть:
 - 3.4.1. airflow (можно airflow-scheduler + airflow-webserver)
 - 3.4.2. minio
 - 3.4.3. mlflow
 - 3.4.4. redis
 - 3.4.5. spark-master
 - 3.4.6. spark-worker (минимум 1)
 - 3.5. Файл [run.sh](#), который

- собирает и запускает ваш проект
 - запускает dag в airflow
 - запускает model serve на порту 6000 в контейнере mlflow
 - дожидается запуска всех сервисов и появления данных
4. Для отладки можно использовать датасет small

Рекомендации

- При сборке образов присваивайте уникальный тег с первыми буквами ФИО.
- Проверяйте свои файлы перед отправкой, удалив старые контейнеры, тома и образы
- Не используйте заглушки

Условия и требования

- Задача выполняется в среде Linux/WSL/MacOS, скрипты для Windows не принимаются.
- Все запускается с помощью команды run.sh
- Оценивается структура docker-compose, DAG и запуск инференса фичей из redis на запущенной модели в контейнере mlflow
 - в docker-compose должны быть сервисы airflow(airflow-scheduler + airflow-webserver), minio, mlflow, redis, spark-master, spark-worker-*
 - в airflow DAG должны быть задачи get_dataset, put_dataset, split_dataset, features_engineering_train, features_engineering_test, load_features, train_and_save_model
 - из redis можно взять данные и дать их на вход запущенной в MLflow модели
- Автоматическая обработка сданных ДЗ происходит раз в час, данные будут появляться в таблице в гугл-доке на листе hw3_check
- pandas разрешен только в скриптах в папке **mlflow**

Формат сдачи задания

Загрузка zip-файла через бота

Внимание! Формат rar не принимается!

Дедлайны:

- Дедлайн для самых уверенных 2025-10-28 18:00 – 15 баллов
- Мягкий дедлайн до 2025-11-04 18:00 – 10 баллов
- Жесткий дедлайн до 2025-11-11 18:00 – после мягкого дедлайна снижаем каждый день по 1 баллу, после дедлайна можно получить только 0